

Chapter 4. Utility Maximization / 效用最大化

如之前设定, $\Omega = \{\omega_1, \dots, \omega_n\}$, \mathbb{P} 为 Ω 上的一个概率测度.

$S = (S_t)_{t=0, \dots, T}$: 股票价格演化过程,

$S_t: \Omega \rightarrow \mathbb{R}$.

$\mathbb{F} = (F_t)_{t=0, \dots, T}$: 由 S 生成的信息流 (filtration).

我们将一直假设市场 S 满足无套利条件 (No Arbitrage). 特别地, 由 Fundamental Theorem of Asset Pricing (定理 2.6) 可知此时存在一个等价鞅测度 (Equivalent Martingale Measure) $\mathbb{Q} \in \mathcal{M}^e(S)$.

现在我们考虑一个“效用函数” (utility function) $U: [0, \infty) \rightarrow \mathbb{R} \cup \{-\infty\}$, $U(x)$ 代表在 T 时刻, 市场参与者 (agent) 的最终财富为 x 时所感受到的“幸福感”. 我们假设 U 满足以下条件:

关于 U 的设定 4.1:

- (1) $U: [0, \infty) \rightarrow \mathbb{R} \cup \{-\infty\}$ 为严格递增函数,
- (2) U 在 $(0, \infty)$ 上连续可微 (continuously differentiable), 即对于任何 $x \in (0, \infty)$, 导数 $U'(x)$ 存在且 $U'(x)$ 为关于 x 的连续函数,
- (3) $U: [0, \infty) \rightarrow \mathbb{R} \cup \{-\infty\}$ 为凹函数 (concave function), 即对于任何 $x, y \in [0, \infty)$, $\lambda \in [0, 1]$,

$$U(\lambda x + (1-\lambda)y) \geq \lambda U(x) + (1-\lambda)U(y).$$

特别地, $U'(x)$ 为严格递减函数,

$$(4) \quad u'(\infty) := \lim_{x \rightarrow \infty} u'(x) = 0,$$

(5) $u(x) > -\infty$ 对任何 $x \in (0, \infty)$ 成立, 且满足 Inada 条件:

$$u'(0) := \lim_{x \downarrow 0} u'(x) = +\infty.$$

例子 4.2: 以下函数满足设定 4.1 (请验证!)

$$\bullet \quad u(x) = \begin{cases} \ln(x), & x > 0, \\ -\infty, & x = 0. \end{cases}$$

$$\bullet \quad u(x) = \frac{x^\alpha}{\alpha}, \quad \alpha \in (0, 1).$$

令 \mathcal{H} 代表所有可预测过程 (Predictable process) 的集合, 我们想要优化的目标函数 (也被称为价值函数 value function) 有以下表示:

$$u(x) = \sup_{H \in \mathcal{H}} \mathbb{E}_P \left[u \left(x + \int_0^T H ds \right) \right], \quad x \in [0, \infty).$$

显然, $u(x)$ 所代表的经济含义是: 在起始资金为 x 的前提下, 通过寻找最优的投资策略 \hat{H}^∞ 以最大化 T 时刻的平均效用值.

我们首先考虑这个优化问题在 完备市场 (Complete Market) 的假设下的解决思路.

4.1. 效用最大化问题 - 完备市场

我们假设市场 S 是完备的 (Complete) 即, S 无套利, 且 $M^e(S) = \{\mathbb{Q}\}$ 仅包含一个唯一的等价鞅测度 (Equivalent Martingale Measure).

由定理 3.2 可知, 此时任何 \mathcal{F}_T 可测的随机变量 $X: \Omega \rightarrow \mathbb{R}$ 均可以被表示为

$$X = \mathbb{E}_{\mathbb{Q}}[X] + \int_0^T H ds. \quad (H \text{ 为某个可预测过程})$$

这意味着我们有: 对任何起始资金 $x \geq 0$,

$$K(x) \stackrel{\text{定义}}{=} \left\{ x + \int_0^T H ds : H \in \mathcal{H} \right\}$$

$$= \left\{ X: \Omega \rightarrow \mathbb{R} (\mathcal{F}_T \text{ 可测}) : \mathbb{E}_{\mathbb{Q}}[X] = x \right\},$$

且显然有

$$u(x) = \sup_{H \in \mathcal{H}} \mathbb{E}_{\mathbb{P}}[U(x + \int_0^T H ds)]$$

$$= \sup_{X \in K(x)} \mathbb{E}_{\mathbb{P}}[U(X)].$$

对于 $X \in K(x)$, 将 $X(\omega_i)$ 记为 ξ_i , $i = 1, \dots, n$; 同时令 $q_i = \mathbb{Q}(\{\omega_i\})$, $i = 1, \dots, n$,

那么此时约束条件 $\mathbb{E}_{\mathbb{Q}}[X] = x$ 可被表示为:

$$\sum_{i=1}^n q_i \xi_i = q_1 \xi_1 + \dots + q_n \xi_n = x,$$

从而我们得到, 价值函数 $u(x)$ 实际上对应优化问题:

$$\begin{cases}
 \mathbb{E}_P[U(X)] = \sum_{i=1}^n p_i U(\xi_i) \rightarrow \max! & \text{(即寻找最优的 } \hat{\xi}_1, \dots, \hat{\xi}_n \text{ 使} \\
 \uparrow & \sum_{i=1}^n p_i U(\hat{\xi}_i) \geq \sum_{i=1}^n p_i U(\xi_i) \\
 p_i = \mathbb{P}(\{\omega_i\}), i=1, \dots, n & \text{对任何 } (\xi_1, \dots, \xi_n) \in \mathbb{R}^n \\
 & \text{(这里令 } \underline{U(X) = -\infty} \text{ 对任何 } X < 0\text{)} \\
 \\
 \text{约束条件: } \sum_{i=1}^n q_i \xi_i = X & ((\xi_1, \dots, \xi_n) \in \mathbb{R}^n \text{ 必须满足 } \xi_1 q_1 + \dots + \xi_n q_n = X)
 \end{cases}$$

要解决这类优化问题, 我们引入 Lagrangian 函数

$$\begin{aligned}
 \underline{L(\xi_1, \dots, \xi_n, y)} &= \sum_{i=1}^n p_i U(\xi_i) - y \left(\sum_{i=1}^n q_i \xi_i - X \right) \\
 &= \sum_{i=1}^n p_i \left(U(\xi_i) - y \frac{q_i}{p_i} \xi_i \right) + yX,
 \end{aligned}$$

这里 $y \geq 0$ 即是 Lagrangian multiplier.

$$\text{令 } \underline{\Psi(y)} = \sup_{\xi_1, \dots, \xi_n} L(\xi_1, \dots, \xi_n, y), \quad y \geq 0.$$

$$\text{显然, 若 } y \geq 0 \text{ 固定, 则 } \underline{\Psi(y)} = \sup_{\xi_1, \dots, \xi_n} \sum_{i=1}^n p_i \left(U(\xi_i) - y \frac{q_i}{p_i} \xi_i \right) + yX$$

$$= \sum_{i=1}^n \left[\sup_{\xi_i \geq 0} \left(U(\xi_i) - y \frac{q_i}{p_i} \xi_i \right) \right] p_i + yX.$$

我们将要证明

$$\left(\inf_{y \geq 0} \Psi(y) = U(X), \right)$$

且 $\inf_{y \geq 0} \Psi(y)$ 的极小值点 \hat{y} ($= \hat{y}(x)$) 满足:
 注意 \hat{y} 依赖于 x

$$\text{令 } \hat{\xi}_1 = (U')^{-1}(\hat{y} \frac{q_1}{p_1}), \quad \dots, \quad \hat{\xi}_n = (U')^{-1}(\hat{y} \frac{q_n}{p_n}),$$

那么 $(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y})$ 是函数 $L(\xi_1, \dots, \xi_n, y)$ 的极值点, 即

$$\left. \frac{\partial}{\partial \xi_i} L(\xi_1, \dots, \xi_n, y) \right|_{(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y})} = 0, \quad i = 1, \dots, n,$$

$$\left. \frac{\partial}{\partial y} L(\xi_1, \dots, \xi_n, y) \right|_{(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y})} = 0,$$

且 $\hat{\xi}_1 q_1 + \dots + \hat{\xi}_n q_n = x.$

因此, $(\hat{\xi}_1, \dots, \hat{\xi}_n)$ 是优化问题 $u(x) = \max_{(\xi_1, \dots, \xi_n)} \sum_{i=1}^n p_i u(\xi_i)$ 在约束条件 $\sum_{i=1}^n q_i \xi_i = x$

下的一组最优解.

基于以上事实, 我们研究的重心现在转移至函数 $\Psi(y)$ 上. 由于已知

$$\Psi(y) = \sum_{i=1}^n \left[\sup_{\xi_i \geq 0} \left(u(\xi_i) - y \frac{q_i}{p_i} \xi_i \right) \right] p_i + yx,$$

我们不妨先研究优化问题

$$\underline{V}(\eta) := \sup_{\xi \geq 0} (u(\xi) - \eta \xi), \quad \eta \geq 0.$$



对应

$$\sup_{\xi_i \geq 0} \left(u(\xi_i) - y \frac{q_i}{p_i} \xi_i \right), \quad i = 1, \dots, n,$$

显然此处 $\eta = y \frac{q_i}{p_i}.$

定义 4.3:

$$V(\eta) = \sup_{\xi \geq 0} [U(\xi) - \eta \xi], \quad \eta \geq 0$$

被称为函数 U 的 共轭函数 (Conjugate).

若 U 满足 设定 4.1, 那么容易证明它的共轭函数 V 满足:

- $V(\eta) \in \mathbb{R}$ 对任何 $\eta \in (0, \infty)$,
- $V(\eta)$ 在 $(0, \infty)$ 上连续可微,
- $V(\eta)$ 在 $(0, \infty)$ 上为凸函数 (convex function), $V'(\eta)$ 为严格递增,
- $V'(0) = \lim_{\eta \downarrow 0} V'(\eta) = -\infty, \quad \lim_{\eta \rightarrow \infty} V'(\eta) (= V(\infty)) = 0,$

$$\lim_{y \rightarrow \infty} V(y) (= V(\infty)) = \lim_{x \rightarrow 0} U(x).$$

以下结果为凸分析的经典结论:

定理 4.4: 若 U 满足 设定 4.1, 那么它的共轭 $V(\eta) = \sup_{\xi \geq 0} [U(\xi) - \eta \xi], \eta \geq 0$

满足以上性质, 且有

$$\underline{U(\xi) = \inf_{\eta \geq 0} [V(\eta) + \eta \xi]}, \quad \xi \in [0, \infty).$$

此外, $-V'$ 是 U' 的逆映射, 即 $-V'(\eta) = (U')^{-1}(\eta)$.

为了简单表示, 我们令 $I = -V' = (U')^{-1}$.

由于

$$\Psi(y) = \sum_{i=1}^n p_i \left(\underbrace{\sup_{\xi_i \geq 0} [u(\xi_i) - (y \frac{q_i}{p_i}) \xi_i]}_{V(y \frac{q_i}{p_i})} \right) + yx,$$

利用 V 的定义可得:

$$\Psi(y) = \sum_{i=1}^n p_i \underbrace{V(y \frac{q_i}{p_i})}_{V(y \frac{q_i}{p_i})} + yx.$$

\triangleq $V(y) := \sum_{i=1}^n p_i V(y \frac{q_i}{p_i})$, 则显然有 $v(y) = \mathbb{E}_{\mathbb{P}}[V(y \frac{dQ}{dP})]$, 且

$$\underline{\Psi(y) = V(y) + xy.}$$

由于 V 在 $(0, \infty)$ 上连续可微, 易推导出 $v(y) = \sum_{i=1}^n p_i V(y \frac{q_i}{p_i})$ 也在 $y \in (0, \infty)$ 上连续可微.

此时, 优化问题 $\inf_{y>0} \Psi(y)$ 可以被表示为

$$\inf_{y>0} \underline{\Psi(y)} = \inf_{y>0} (v(y) + xy).$$

由于 V 在 $(0, \infty)$ 上连续可微, $y \mapsto v(y) + xy$ 在 $y \in (0, \infty)$ 上有(唯一)极值点,

$\hat{y} (= \hat{y}(x))$ 使得 $v'(\hat{y}(x)) = -x$. 易验证

$$\begin{aligned} \inf_{y>0} \underline{\Psi(y)} &= \inf_{y>0} (v(y) + xy) = v(\hat{y}(x)) + x\hat{y}(x) \\ &= \underline{\Psi}(\hat{y}(x)) \\ &= \sup_{\xi_1, \dots, \xi_n} L(\xi_1, \dots, \xi_n, \hat{y}(x)). \end{aligned}$$

$$\text{由于 } L(\xi_1, \dots, \xi_n, \hat{y}(x)) = \sum_{i=1}^n p_i (u(\xi_i) - \hat{y}(x) \frac{q_i}{p_i} \xi_i) + xy,$$

易求得其极值点为

$$u'(\hat{\xi}_1) = \hat{y}(x) \frac{q_1}{p_1} \Rightarrow \underline{\hat{\xi}_1 = (u')^{-1}(\hat{y}(x) \frac{q_1}{p_1}) = I(\hat{y}(x) \frac{q_1}{p_1})},$$

⋮

$$u'(\hat{\xi}_n) = \hat{y}(x) \frac{q_n}{p_n} \Rightarrow \underline{\hat{\xi}_n = (u')^{-1}(\hat{y}(x) \frac{q_n}{p_n}) = I(\hat{y}(x) \frac{q_n}{p_n})}.$$

特别地, 我们有:

$$\underline{\inf_{y>0} \Psi(y)} = \Psi(\hat{y}(x)) = \sup_{\xi_1, \dots, \xi_n} L(\xi_1, \dots, \xi_n, \hat{y}(x)) = \underline{L(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y}(x))}.$$

注意, 由于 $\hat{y}(x)$ 满足

$$\underline{v'(\hat{y}(x)) = -x},$$

$$\text{即 } \sum_{i=1}^n p_i V'(\hat{y}(x) \frac{q_i}{p_i}) \frac{q_i}{p_i} = -x \quad (\text{利用 } v(y) = \sum_{i=1}^n p_i V(y \frac{q_i}{p_i})),$$

$$\text{可知 } \sum_{i=1}^n q_i (-V')(\hat{y}(x) \frac{q_i}{p_i}) = x.$$

由于 $I = -V'$, 若 $\hat{\xi}_i = I(\hat{y}(x) \frac{q_i}{p_i})$, $i=1, \dots, n$, 那么必有:

$$\underline{\sum_{i=1}^n q_i \hat{\xi}_i = \sum_{i=1}^n q_i (-V')(\hat{y}(x) \frac{q_i}{p_i}) = x}.$$

因此 $(\hat{\xi}_1, \dots, \hat{\xi}_n)$ 满足约束条件 $\sum_{i=1}^n q_i \hat{\xi}_i = x$. 由此又得到:

$$\begin{aligned} L(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y}(x)) &= \sum_{i=1}^n p_i u(\hat{\xi}_i) - \hat{y}(x) \underbrace{\left(\sum_{i=1}^n q_i \hat{\xi}_i - x \right)}_{=0} \\ &= \sum_{i=1}^n p_i u(\hat{\xi}_i). \end{aligned}$$

现在我们证明:

$$u(x) = \sup_{\xi_1, \dots, \xi_n} \sum_{i=1}^n p_i u(\xi_i)$$

$$\left\{ \begin{array}{l} \text{约束条件: } \sum_{i=1}^n q_i \xi_i = x \end{array} \right.$$

$$= \sum_{i=1}^n p_i u(\hat{\xi}_i) = L(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y}(x)).$$

显然, 由于 $\sum_{i=1}^n q_i \hat{\xi}_i = x$, 必有 $u(x) \geq \sum_{i=1}^n p_i u(\hat{\xi}_i) = L(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y}(x))$.

另一方面, 对任何满足约束条件 $\sum_{i=1}^n q_i \xi_i = x$ 的 (ξ_1, \dots, ξ_n) , 必然有

$$\sum_{i=1}^n p_i u(\xi_i) \leq L(\xi_1, \dots, \xi_n, \hat{y}(x)) \leq L(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y}(x)),$$

$$\text{因为 } L(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y}(x)) = \sup_{(\xi_1, \dots, \xi_n)} L(\xi_1, \dots, \xi_n, \hat{y}(x)).$$

$$\text{因此 } u(x) = \left\{ \begin{array}{l} \sup_{\xi_1, \dots, \xi_n} \sum_{i=1}^n p_i u(\xi_i) \\ \sum_{i=1}^n q_i \xi_i = x \end{array} \right. \leq L(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y}(x)).$$

从而有

$$\underline{u(x) = L(\hat{\xi}_1, \dots, \hat{\xi}_n, \hat{y}(x))} = \inf_{y \geq 0} \Pi(y) = \inf_{y \geq 0} (v(y) + xy).$$

$$= \underline{v(\hat{y}(x)) + x\hat{y}(x)}.$$

我们将以上分析得到的结果总结为以下定理:

定理 4.5 (完备市场上的效用最大化):

假设市场 S 满足无套利且 $M^e(S) = \{\mathbb{Q}\}$, 即 S 为一个完备市场. 假设效用函数

$U: [0, \infty) \rightarrow \mathbb{R}$ 满足设定 4.1.

$$\text{令 } K(x) = \left\{ x + \int_0^T H dS : H \in \mathcal{H} \right\} = \left\{ X: \Omega \rightarrow \mathbb{R} : \mathbb{E}_{\mathbb{Q}}[X] = x \right\}.$$

$$\text{令 } \underline{u(x)} = \sup_{H \in \mathcal{H}} \mathbb{E}_{\mathbb{P}} \left[U \left(x + \int_0^T H dS \right) \right] = \sup_{X \in K(x)} \mathbb{E}_{\mathbb{P}} [U(X)], \quad x \geq 0.$$

$$\text{令 } \underline{v(y)} = \sum_{i=1}^n q_i V \left(y \frac{q_i}{p_i} \right) = \mathbb{E}_{\mathbb{P}} \left[V \left(y \frac{d\mathbb{Q}}{d\mathbb{P}} \right) \right], \quad \text{这里}$$

$$V(\eta) = \sup_{\xi \geq 0} (U(\xi) - \eta \xi), \quad \eta \geq 0 \text{ 为 } U \text{ 的共轭函数.}$$

我们有以下结论:

$$(i) \quad u(x) = \inf_{y \geq 0} (v(y) + xy), \quad v(y) = \sup_{x \geq 0} (u(x) - xy),$$

即 u 与 v 互为共轭.

$$(ii) \quad \underline{u(x)} = \sup_{X \in K(x)} \mathbb{E}_{\mathbb{P}} [U(X)] \text{ 对应的最优解 } \hat{X} \in K(x) \text{ 满足:}$$

$$\begin{cases} \hat{X}(\omega_i) = \hat{\xi}_i = I \left(\hat{y}(x) \frac{q_i}{p_i} \right), \quad i=1, \dots, n, \quad I = (U')^{-1}, \\ \sum_{i=1}^n q_i \hat{\xi}_i = x, \end{cases}$$

$$\hat{y}(x) \text{ 满足 } \underline{v'(\hat{y}(x)) = -x}, \text{ 即 } \underline{\sum_{i=1}^n q_i (-V') \left(\hat{y}(x) \frac{q_i}{p_i} \right) = x}.$$

$$(iii) \quad u'(x) = \mathbb{E}_{\mathbb{P}} [U'(\hat{X}(x))], \quad v'(y) = \mathbb{E}_{\mathbb{Q}} \left[V' \left(y \frac{d\mathbb{Q}}{d\mathbb{P}} \right) \right].$$

证明: (i) 我们已经推导出 $u(x) = \inf_{y>0} (v(y) + xy)$, 见第9页. 由此利用凸分析里的经典结果 (不要求掌握) 可直接得到 $v(y) = \sup_{x>0} (u(x) - xy)$.

(ii) 已在第9页中证明.

$$(iii) \quad v(y) = \sum_{i=1}^n q_i V(y \frac{q_i}{p_i}), \quad \text{故} \quad v'(y) = \sum_{i=1}^n \cancel{q_i} V'(y \frac{q_i}{p_i}) \frac{q_i}{\cancel{p_i}} = \sum_{i=1}^n q_i V'(y \frac{q_i}{p_i}),$$

$$\text{显然, } \sum_{i=1}^n q_i V'(y \frac{q_i}{p_i}) = \mathbb{E}_{\mathbb{Q}} [V'(y \frac{d\mathbb{Q}}{d\mathbb{P}})].$$

由于 $u(x) = \inf_{y>0} (v(y) + xy) = v(\hat{y}(x)) + x\hat{y}(x)$, 见第9页, 我们有:

$$u'(x) = v'(\hat{y}(x)) \hat{y}'(x) + x\hat{y}'(x) + \hat{y}(x).$$

因为 $v'(\hat{y}(x)) = -x$ (见第8页), 显然又有:

$$u'(x) = -\cancel{x} \hat{y}'(x) + \cancel{x} \hat{y}'(x) + \hat{y}(x) = \hat{y}(x).$$

又由 (ii), 即 $\hat{X}(x) = I(\hat{y}(x) \frac{d\mathbb{Q}}{d\mathbb{P}})$, $I = (U')^{-1}$, 可得:

$$\hat{y}(x) \frac{d\mathbb{Q}}{d\mathbb{P}} = U'(\hat{X}(x)),$$

综上, 可得:

$$u'(x) = \hat{y}(x) = \mathbb{E}_{\mathbb{Q}} [\hat{y}(x)] = \mathbb{E}_{\mathbb{P}} [\hat{y}(x) \frac{d\mathbb{Q}}{d\mathbb{P}}] = \mathbb{E}_{\mathbb{P}} [u'(\hat{X}(x))].$$

\uparrow
 因为 $\hat{y}(x)$ 为常数

故证毕.

□

总结：要解决完备市场上的效用最大化问题，我们依次进行以下步骤：

1. 求出效用函数 U 的共轭 $V(\eta) = \sup_{\xi \geq 0} (U(\xi) - \eta \xi)$, $\eta \geq 0$.

2. 求出函数 $v(y) = \sum_{i=1}^n p_i V(y \frac{q_i}{p_i})$ 的导数 $v'(y)$, 从而求出函数 $v(y) + \lambda y$ 在 $y > 0$ 上的极值点 $\hat{y}(\lambda)$, 即解方程

$$v'(\hat{y}(\lambda)) = -\lambda.$$

或求出 $u(\lambda)$, 利用关系 $\hat{y}(\lambda) = u'(\lambda)$ 求出 $\hat{y}(\lambda)$.

3. 求出 $I = (U')^{-1}$, 即 U' 的逆映射, 利用步骤 2 中得到的 $\hat{y}(\lambda)$ 依次计算

$$\hat{\xi}_1 = I(\hat{y}(\lambda) \frac{q_1}{p_1}), \quad \dots, \quad \hat{\xi}_n = I(\hat{y}(\lambda) \frac{q_n}{p_n}).$$

4. $\hat{\chi}(\lambda)(\omega_i) = \hat{\xi}_i(\omega)$, $i = 1, \dots, n$ 即是 $u(\lambda) = \sup_{\chi \in K(\lambda)} E_p[U(\chi)]$ 在 $K(\lambda)$ 中的最优解; 且 $u(\lambda) = \sum_{i=1}^n p_i U(\hat{\xi}_i(\omega))$ 为最大平均效用.